

DEEP LEARNING

Laboratorio 7

Forecasting de temperatura de aceite con LSTM y Transformer

Autor	Diego López
Carné	23747
Curso	Deep Learning (CC3092)
Sección	20
Fecha de entrega	27 de septiembre de 2026

Decisiones de diseño

El pipeline evita fuga de información y usa la misma configuración experimental para que la comparación entre arquitecturas sea directa.

- Normalización: $z_t = (x_t - \mu)/\sigma$ con μ y σ calculados solo sobre entrenamiento.
- Predicción relativa a x_t : la red recibe $X - x_t$ y aprende $y - x_t$, debido al cambio de nivel entre train y validación/prueba.
- Pérdida MSE, optimizador Adam, 20 épocas, batch size 64 y learning rate 10^{-3} .
- Ejecución en CPU y semilla 42 para PyTorch y NumPy.
- Un modelo independiente por horizonte $H \in \{24, 48\}$; ambos son directos y producen una sola salida.

Task 1 - Preprocesamiento y autocorrelación

1.1 Normalización, split temporal y ventanas

Se descargaron 17,420 observaciones de ETTh1 sin valores NaN. La variable OT se normalizó con estadísticas exclusivas del bloque de entrenamiento y se dividió temporalmente 60/20/20 en bloques contiguos, sin mezcla aleatoria.

Estadística	Valor
μ de train	17.2925
σ de train	8.5137

Split	Pasos	Media normalizada	Desv. estándar
Train	10,452	+0.000	1.000
Validación	3,484	-1.206	0.516
Prueba	3,484	-1.124	0.405

Cada ejemplo usa una ventana $X^{(t)} = (x_{t-L+1}, \dots, x_t)$ y objetivo $y^{(t)} = x_{t+H}$. Para una serie de largo T , $N = T - L - H + 1$.

H	Split	Shape de X	Shape de y
24	Train	(10,333, 96)	(10,333,)
24	Validación	(3,365, 96)	(3,365,)
24	Prueba	(3,365, 96)	(3,365,)
48	Train	(10,309, 96)	(10,309,)
48	Validación	(3,341, 96)	(3,341,)
48	Prueba	(3,341, 96)	(3,341,)

1.2 Función de autocorrelación

La ACF se calculó manualmente sobre train para los lags 0 a 96. La banda de confianza al 95% es ± 0.0192 ; toda la ACF observada queda muy por encima de ella.




Figura 1. ACF de OT normalizada en entrenamiento, con banda de confianza al 95%.

1.2 a. Segundo pico más alto e interpretación

El valor más alto después de lag 0 es lag 1 ($\rho(1)=0.9923$), pero es el inicio del decaimiento y no un pico local. El pico local más alto es lag 22 ($\rho(22)=0.9262$), prácticamente empatado con lag 24 ($\rho(24)=0.9250$); después aparecen lag 47 (0.8770) y lag 72 (0.8572). La separación aproximada de 24-25 horas respalda un ciclo diario sobre una componente lenta y persistente.

- $\rho(12)=0.9250$, $\rho(22)=0.9262$ y $\rho(24)=0.9250$: la zona es casi plana, con diferencias menores que 0.002.
- La secuencia de máximos $22 \rightarrow 47 \rightarrow 72$ confirma una periodicidad cercana a un día.

1.2 b. Adecuación de $L = 96$

$L = 96$ es apropiado porque cubre cuatro ciclos diarios completos. Incluso $\rho(96)=0.8489$, muy por encima de ± 0.0192 , por lo que la historia sigue siendo informativa; sin embargo, extender la ventana agregaría principalmente información redundante y elevaría el costo del LSTM y de la atención.

- Una ventana menor que 24 perdería el ciclo diario completo; $L=48$ conservaría solo dos ciclos.
- De lag 47 a lag 96 la ACF apenas cae de 0.8770 a 0.8489, señal de alta colinealidad.
- Explorar $L=168$ podría probar el ciclo semanal, pero esta ACF hasta 96 no aporta evidencia para justificarlo.

Verificación Task 1

Task 1: CORRECTO (ACF lag24=0.9250, naive_mae=0.2009)

Task 2 - LSTM

2.1 LSTMForecaster manual

La celda LSTM procesa manualmente cada paso, apila las cuatro compuertas y usa el último estado oculto para producir una predicción escalar many-to-one.

$$[i; f; g; o] = x_t W_x^T + h_{t-1} W_h^T + b; \quad i, f, o = \sigma(\cdot), \quad g = \tanh(\cdot)$$

$$c_t = f \odot c_{t-1} + i \odot g; \quad h_t = o \odot \tanh(c_t); \quad \hat{y} = h_t W_{out}^T + b_{out}$$

2.2 Entrenamiento y evaluación

Se entrenó un LSTM distinto por horizonte con $d_h=32$. Validación y prueba están aproximadamente 1.2 desviaciones por debajo de train y presentan cerca de la mitad de variabilidad, por lo que se entrenó sobre diferencias respecto del último valor observado x_t . La predicción final vuelve a nivel absoluto mediante $\hat{y} = x_t + f(X - x_t)$.

La MSE fue elegida por tratarse de regresión continua, penalizar con más fuerza los errores grandes, ofrecer un gradiente suave y ser coherente con el RMSE reportado. El MAE se conserva como métrica interpretable en °C.

Modelo	H	MAE	RMSE	Ratio	MAE °C	RMSE °C
LSTM	24	0.2040	0.2694	1.015	1.736	2.294
LSTM	48	0.2601	0.3331	0.993	2.214	2.836
Naive	24	0.2009	0.2689	1.000	1.710	2.289
Naive	48	0.2620	0.3380	1.000	2.231	2.878

El LSTM queda prácticamente empatado con naive: en H=24 su MAE es ligeramente peor, mientras que en H=48 lo mejora apenas. Las pérdidas se estabilizan muy pronto; el modelo aprende una corrección pequeña sobre x_t y deja de mejorar de forma sostenida.




Figura 2. Curvas de pérdida MSE de entrenamiento del LSTM para H=24 y H=48.

Verificación Task 2

Task 2: CORRECTO
LSTM H=24: MAE=0.2040, ratio=1.015

Task 3 - Transformer

3.1 Positional encoding

Cada valor escalar se proyecta a $\mathbb{R}^{d_{\text{model}}}$ con una capa lineal y luego se suma un positional encoding sinusoidal no aprendible. El tensor resultante tiene shape (96, 32) y `requires_grad=False`.

$$\text{PE}(t, 2i) = \sin(t / 10000^{2i/d_{\text{model}}}), \quad \text{PE}(t, 2i+1) = \cos(t / 10000^{2i/d_{\text{model}}})$$

3.2 Multi-head self-attention, LayerNorm y FFN

El encoder implementa manualmente dos cabezas de atención. Tras cada subcapa se aplica conexión residual y normalización; la salida se toma de la posición 0, usada como CLS aunque corresponde al dato más antiguo de la ventana.

$$Q=XW_Q, \quad K=XW_K, \quad V=XW_V; \quad \text{head}_h = \text{softmax}(Q_h K_h^T / \sqrt{d_k}) V_h$$

$$\text{MHA}(X) = [\text{head}_1; \dots; \text{head}_H] W_O; \quad \text{LN}(x) = \gamma (x - \mu) / \sqrt{(\sigma^2 + \epsilon)} + \beta; \quad \text{FFN}(x) = \text{ReLU}(xW_1 + b_1)W_2 + b_2$$

3.3 Entrenamiento, evaluación y mapas de atención

Se entrenó un Transformer por horizonte con $d_{\text{model}}=32$, dos cabezas, $d_{\text{ff}}=64$ y las mismas condiciones del LSTM. La tabla muestra las métricas de validación y el baseline naïve.

Modelo	H	MAE	RMSE	Ratio	MAE °C	RMSE °C
Transformer	24	0.2066	0.2589	1.029	1.759	2.204
Transformer	48	0.2413	0.3160	0.921	2.055	2.690
Naive	24	0.2009	0.2689	1.000	1.710	2.289
Naive	48	0.2620	0.3380	1.000	2.231	2.878

Los mapas promedian cinco ventanas de validación y dos cabezas. Para $H=24$ se usaron los índices [0, 841, 1682, 2523, 3364]; para $H=48$, [0, 835, 1670, 2505, 3340].




Figura 3. Mapas de atención promedio para $H=24$ y $H=48$.

3.3 d. Posiciones con mayor atención desde CLS

La atención desde CLS se concentra en bandas lejanas, no en los lags más recientes. Las franjas verticales indican que distintas queries tienden a mirar las mismas keys, por lo que el patrón depende en gran medida de la posición y el contenido de la key.

- $H=24$: lags 77-81, con máximos en lag 80 (0.1095) y 79 (0.1033); segunda banda en 45-49, con lag 47=0.0473 y lag 48=0.0452.
- $H=48$: lags 70-74, con lag 73=0.0598 y lag 72=0.0584; también lag 79=0.0458 y lags 45-48 alrededor de 0.03-0.035.
- El peso uniforme sería $1/96=0.0104$; lag 1 recibe 0.0002 en $H=24$ y 0.0013 en $H=48$.

Verificación Task 3

```
Task 3: CORRECTO
attn_w shape: torch.Size([4, 2, 96, 96])
row sums OK: 1.0000 a 1.0000
```

Task 4 - Comparación e interpretación

4.1 ACF frente a atención

4.1 a. Coincidencia de los lags

Los lags de mayor atención coinciden solo parcialmente con los picos de la ACF. La ACF es máxima en lags cortos y decae, mientras que la atención casi ignora esos lags y privilegia algunas bandas lejanas.

Lag	ACF	Atención H=24	Atención H=48
1	0.9923	0.0002	0.0013
22 (pico ACF)	0.9262	0.0016	0.0018
24	0.9250	0.0104	0.0032
47 (pico ACF)	0.8770	0.0473	0.0339
48	0.8763	0.0452	0.0298
72 (pico ACF)	0.8572	0.0079	0.0584
79	0.8361	0.1033	0.0458
80	0.8334	0.1095	fuera del top

La correlación de Spearman entre los perfiles completos de lags 1-96 es negativa: -0.209 para H=24 y -0.323 para H=48. La coincidencia aparece en lag 47/48 para ambos horizontes y en lag 72 para H=48; la banda 78-81 de H=24 no corresponde a un pico de la ACF.

La diferencia es coherente con que la ACF mide redundancia lineal, mientras que el modelo minimiza el MSE del cambio y busca información complementaria. Al centrar en x_t , los valores recientes aportan poco; los lags 48 y 72 corresponden a una hora del día comparable con el objetivo, y la banda cercana a 80 puede servir como referencia de tendencia de varios días.




Figura 4. Perfil de ACF frente a atención desde CLS para H=24 y H=48.

4.1 b. Dependencias no lineales

La ACF asigna un único valor lineal y estacionario a cada lag. En cambio, los scores de atención dependen de proyecciones aprendidas de los valores y pueden variar con el contenido, el régimen y la hora del día; además, la interacción query-key es bilineal y se combina con softmax y una FFN con ReLU.

- El coeficiente de variación medio entre ejemplos es 0.597 para H=24 y 0.606 para H=48.
- En H=48 el lag de máxima atención cambia por ejemplo: [72, 73, 80, 79, 67].
- En H=24 el máximo permanece en 79-80, pero cambian los picos secundarios en torno a 23-28, 45-47 y 68.

La evidencia de dependencia condicionada por el contenido existe, aunque es moderada: cinco ejemplos son pocos y las franjas verticales revelan un componente posicional fuerte.




Figura 5. Atención desde CLS por ejemplo de validación para H=24 y H=48.

4.2 Comparación LSTM, Transformer y naive

La comparación completa se presenta una sola vez. Todas las métricas corresponden a validación y a la escala normalizada; las dos últimas columnas convierten los errores a grados Celsius.

Modelo	Horizonte	MAE	RMSE	Ratio vs naive	MAE °C	RMSE °C
LSTM	24 h	0.2040	0.2694	1.015	1.736	2.294
LSTM	48 h	0.2601	0.3331	0.993	2.214	2.836
Transformer	24 h	0.2066	0.2589	1.029	1.759	2.204
Transformer	48 h	0.2413	0.3160	0.921	2.055	2.690
Naive	24 h	0.2009	0.2689	1.000	1.710	2.289
Naive	48 h	0.2620	0.3380	1.000	2.231	2.878

4.2 a. Aumento del error con el horizonte

En predicción iterativa, el error se propaga como $e_{t+h} \approx \varepsilon_{t+h} + J e_{t+h-1}$, de modo que $e_{t+h} \approx \sum_{j=0}^{h-1} J^j \varepsilon_{t+h-j}$ y $\text{Var}(e_{t+h}) \approx \sigma^2 \sum_{j=0}^{h-1} J^{2j}$. Con $\rho(1)=0.99$, $J \approx 1$ y la acumulación sería casi lineal.

Sin embargo, los dos modelos implementados son **directos de una sola salida**: se entrena un modelo separado para cada H y ninguno realimenta predicciones. El error aumenta por la incertidumbre intrínseca del futuro más lejano. Para un predictor lineal basado solo en x_t , $1-\rho(H)^2$ vale 0.1445 en H=24 y 0.2320 en H=48, un factor de 1.61.

Modelo	MSE H=24	MSE H=48	Factor
Naive	$0.2689^2 = 0.0723$	$0.3380^2 = 0.1142$	1.58
LSTM	0.0726	0.1110	1.53
Transformer	0.0670	0.0999	1.49

4.2 b. Flujo del gradiente

En H=48 el Transformer supera al LSTM (MAE 0.2413 frente a 0.2601; RMSE 0.3160 frente a 0.3331). En H=24 no lo supera en MAE (0.2066 frente a 0.2040), aunque sí en RMSE (0.2589 frente a 0.2694).

En el LSTM, $\partial L / \partial h_k = (\partial L / \partial h_T) \prod_{t=k+1}^T \partial h_t / \partial h_{t-1}$ y $\partial c_t / \partial c_{t-1} = \text{diag}(f_t)$. El gradiente hacia lags 48-80 atraviesa decenas de factores y puede decaer geométricamente.

En el Transformer, $o_0 = \sum_s \alpha_{0s} v_s W_O$, de modo que existe un camino de longitud 1 desde cualquier posición atendida hasta la salida. Esto facilita aprender de lags lejanos como 45-48 y 70-74, precisamente donde se concentra el modelo H=48. La loss H=48 del LSTM queda aproximadamente entre 0.218 y 0.235, mientras la del Transformer baja de 0.1907 a 0.1794.

Uso de IA generativa

Se documenta, por cada task, el prompt exacto utilizado y la razón por la que resultó útil, conforme a las instrucciones del laboratorio.

Task 1

Prompt exacto

[COMPLETAR POR EL USUARIO]

Por qué funcionó

[COMPLETAR POR EL USUARIO]

Task 2

Prompt exacto

[COMPLETAR POR EL USUARIO]

Por qué funcionó

[COMPLETAR POR EL USUARIO]

Task 3

Prompt exacto

[COMPLETAR POR EL USUARIO]

Por qué funcionó

[COMPLETAR POR EL USUARIO]

Task 4

Prompt exacto

[COMPLETAR POR EL USUARIO]

Por qué funcionó

[COMPLETAR POR EL USUARIO]